

НОВЫЙ МАТЕМАТИЧЕСКИЙ МЕТОД ОБНАРУЖЕНИЯ АНОМАЛИЙ В ПРИРОДНЫХ ВРЕМЕННЫХ РЯДАХ

КАЛМАК Д.А.¹, МАНДРИКОВА Б.С.^{1,2}, МАНДРИКОВА О.В.²

СПбГЭТУ «ЛЭТИ»¹, ИКИР ДВО РАН²

Таблица 1 – Метрики регрессии

Метрики / Эксперимент	MSE	MAE	RMSE	MAPE, %	MASE	L1/L2
Тестовые данные	0.060	0.245	0.245	0.15	0.287	1171.635 / 20.572
Случайный участок тестовых данных на 60 точек	0.115	0.214	0.340	0.19	0.304	12.843 / 2.630
Наименее благоприятный случай (нефильтрованные, неизвестные данные неизвестного диапазона)	1.804	1.072	1.343	1.09	1.055	309.725 / 22.833

1-2 – 2018, 3 – 04.2026, nmdsh.eu

Разработанная модель демонстрирует в таблице 1 высокую точность и стабильность на данных тестовой выборки и сохраняет приемлемое качество на отдельном участке выборки. При переходе к наименее благоприятному сценарию: нефильтрованным данным, выходящим за пределы обучающего распределения – качество прогнозирования может существенно снижаться. Данная проблема решается улучшенным обучением нейронной сети за счет больших вычислительных мощностей, а также компенсируется модулем обнаружения аномалий, определяющим, когда реальное значение считается аномалией в сравнении с предсказанным, и модулем фильтрации.

При экстремальных условиях метод обнаружения показал в таблице 2 внушительный результат сравнимый с аналогами, когда аномалии проявляют свои особенности, затрудняющие их обнаружение, а данные являются наименее благоприятным случаем для модели, и даже превосходящие результаты при аномалии без особенностей.

Таблица 2 – Метрики обнаружения аномалий

Эксперимент / Метрики	GLE	GLE (<%)	GLE (>%)	FD	FD (до min)	FD (<%)
Покрытие индексов (Recall), %	100.00	100.00	100.00	71.91	76.12	83.15
Ложные срабатывания, %	4.88	17.07	0	4.89	4.89	19.56
Сдвиги начала	0	0	0	2	2	0
Precision, %	97.55	91.92	100.00	85.33	82.26	62.71
F1-score, %	98.76	95.79	100.00	78.05	79.07	71.50
IoU, %	97.55	91.92	100.00	64.00	65.38	55.64

GLE – 11.25, FD – 05.24, nmdsh.eu

Задачи прогноза возмущений в околоземном космическом пространстве и магнитных бурь с каждым годом набирают актуальность, поскольку солнечно-земные явления напрямую влияют на критически важную инфраструктуру и повседневную жизнь, а современные системы все сильнее зависят от надежных предупреждений и управляемых мер. Известно, что в результате прохождения через Землю облаков магнитных и ударных структур, возникающих после событий на Солнце (высокоскоростных потоков солнечного ветра, Солнечных вспышек, корональных выбросов масс), в данных нейтронных мониторов могут регистрироваться эффекты, связанные с изменением интенсивности космических лучей – падение интенсивности при Форбуш-эффекте или повышение интенсивности при событиях GLE.

Целью работы является построение цифровой модели временного ряда наблюдений нейтронных мониторов и численного метода обнаружения аномалий в данных космических лучей.

В настоящей работе предложен математический метод анализа данных нейтронных мониторов, основанный на применении нейронной сети архитектуры Колмогорова-Арнольда и пороговых функций. На основе нейронной сети решается задача регрессии временного ряда. Вейвлет-фильтрация способствует точности регрессии, усилению полезного сигнала и убирает шум из данных. С помощью порогового отклонения выполняется обнаружение аномалий во временном ряду, возникающих накануне и во время магнитных бурь. Метод реализован программно и может быть использован в режиме онлайн. Результат важен для задач космической погоды.

Архитектура KAN представлена на рис. 1. Выбран кубический сплайн и пять интервалов сетки. Фильтрация основана на вейвлете Добеши 3-го порядка и жесткой пороговой функции.




Рис. 1. Архитектура НС KAN.

Нормализация log + MinMaxScaler проводится у каждого среза данных. Нейронная сеть выделяет особенности каждого среза в отдельности и использует эти данные для предсказания, что позволяет работать даже в неизвестных диапазонах.

Архитектура системы обнаружения аномалий в данных нейтронного монитора представлена на рис. 2.



Рис. 2. Архитектура системы обнаружения природных аномалий.

Реализован программный комплекс, который позволяет обучать, тестировать, валидировать модель нейронной сети KAN, обрабатывать и визуализировать данные, а графическое приложение позволяет работать в режиме с файлом данных нейтронного монитора или в режиме реального времени с нейтронным монитором. Пример использования приложения в реальной ситуации с поступлением нефильтрованных неизвестных данных нейтронного монитора в режиме реального времени посредством встроенной имитации представлен на рис. 3. При обнаружении аномалии пользователю выводится мигающее сообщение, которое информирует об обнаружении аномалии и будет мигать до тех пор, пока пользователь не нажмет кнопку «Зафиксировать аномалию», а потом подтвердит, что хочет зафиксировать. Мигающее сообщение появится вновь, если будет зафиксирована новая аномалия.




Рис. 3. Работа приложения в режиме реального времени.

Разработанный метод, обученная модель и программный комплекс могут применяться в научно-исследовательских организациях и центрах мониторинга космической погоды, а также в прикладных областях, связанных с эксплуатацией спутниковых, навигационных и других технических систем, подверженных влиянию космических факторов. Ввиду модульной структуры, в дальнейшем решение может улучшаться за счет улучшения модели и соответственно метрик регрессии, добавления других режимов в модуль обнаружения аномалий помимо процента отклонения, расширение модуля фильтрации на другие типы фильтрации, а также развития программного комплекса в целом, представляющего полноценную среду для практической работы с решением.

Исходный код: <https://github.com/proitshnik/KANAnomalyDetector>